

COMPATIBILIDAD ESPECTRAL ENTREDOMINIOS Y CLASIFICACIÓN NO SUPERVISADA DE COBERTURAS DEL SUELO EN IMÁGENES VIS-NIR EN PAISAJES COLOMBIANOS



**Humath
Space**

**UNIVERSIDAD
EAFIT®**

Pregrado en
**Ingeniería
Física**

JUAN ÁNGEL GÁMEZ DÍAZ¹, SEBASTIÁN CARMONA ESTRADA², OLGA LUCÍA QUINTERO MONTOYA²
^{1,2} EAFIT UNIVERSITY — SCHOOL OF APPLIED SCIENCES AND ENGINEERING, MEDELLÍN, COLOMBIA
JAGAMEZD@EAFIT.EDU.CO¹, SCARMONAE@EAFIT.EDU.CO², OQUINTEI@EAFIT.EDU.CO²

RESUMEN

Estudio del espectro VIS-NIR de **QUEEN-BEE** y su compatibilidad con datos públicos. K-means logró Silhouette 0.57 (Kaggle) y 0.33 (QUEEN-BEE), mostrando mayor variabilidad en escenas colombianas y potencial del VIS-NIR

INTRODUCCION

La observación terrestre permite caracterizar la cobertura del suelo, pero la resolución satelital es limitada para paisajes heterogéneos como los colombianos. Los UAV con sensores **VIS-NIR** ofrecen alta resolución, aunque con desafíos de adquisición y variabilidad entre sensores. Este estudio compara espectralmente datasets públicos y el sistema QUEEN-BEE y evalúa la separabilidad de clases mediante métodos no supervisados.



Figura 1: QUEEN-BEE e imágenes NIR-RGB.

FUNDAMENTOS

- Las imágenes VIS-NIR permiten diferenciar materiales y coberturas gracias a sus patrones de reflectancia.
- La compatibilidad entre datasets se analiza con métricas como Pearson (correlación) y Chi-square (divergencia).
- La estructura intrínseca de los datos puede explorarse con **K-means**, cuyas metricas se evalúa mediante Silhouette, Calinski-Harabasz y Davies-Bouldin.





Figura 2: Histograma acumulado bandas R,G,B-NIR de QUEEN-BEE.

AGRADECIMIENTOS

Agradezco a mis tutores, Sebastián Carmona Estrada y Olga Lucía Quintero, por su guía y acompañamiento durante este proyecto. Como estudiante, su apoyo técnico y académico fue fundamental. También agradezco al equipo de Humath por su colaboración y contribuciones al desarrollo del estudio.

METODOLOGIA

La metodología esta dada por el siguiente esquema:



RESULTADOS

El análisis evidenció compatibilidad espectral entre VEDAI y **QUEEN-BEE** en la banda NIR ($\rho \approx 0.62$). En clasificación no supervisada, Kaggle mostró alta separabilidad (Silhouette = 0.57) y **QUEEN-BEE** valores moderados (≈ 0.33), reflejando diferencias geográficas y de adquisición. Aun así, K-means logró clústeres coherentes para vegetación, edificaciones y vías.




Figura 3: Histogramas acumulados de 4 clases de VEDAI y QUEEN-BEE.

Class	Pearson Correlation	Normalized Chi-square
Car	0.6209	0.6245
Truck	-0.0872	0.9612
Light aircraft	0.4010	0.7773
Pickup truck	0.6186	0.5689

Figura 4: Metricas estadísticas y clase carro de VEDAI y QUEEN-BEE.

Dataset	Silhouette	Calinski-Harabasz	Davies-Bouldin
L1	0.3190	69,237	1.0240
L2	0.3332	21,325	0.9331
Kaggle	0.5692	231,292	0.5577

Figura 5: Métricas aplicadas a modelo k-means.




Figura 7: Imagen de QUEEN-BEE original y segmentada por k-means.




Figura 6: Coeficiente de silueta vs # clusters.

CONCLUSIONES

- Se identificó alta compatibilidad espectral entre VEDAI y **QUEEN-BEE** en clases “car” y “pickup truck”, $\rho \approx 0.62$), lo que demuestra potencial de transferencia entre dominios.
- La variabilidad de las **escenas colombianas** genera baja separabilidad comparada con benchmarks (Silhouette: 0.57 vs. 0.33).
- K-means** logró distinguir patrones estables en vegetación, edificaciones y vías, mostrando que las bandas VIS-NIR contienen información útil incluso sin supervisión.

REFERENCIAS

[1] D. A. Chiran Taimal, Optimización del monitoreo ambiental mediante aplicaciones digitales en reforestaciones y restauraciones ecológicas en Cumbal, Colombia, 2024.
[2] C. A. Pedraza Peñaloza, Novel methods and technologies to improve monitoring and understanding of land use land cover dynamics based on satellite Earth Observation: The case of forest monitoring in Colombia, 2023.
[3] J. A. Achicanoy, R. Rojas-Robles, and J. E. Sánchez, “Land cover vegetation analysis and projection through remote sensing and Geographic Information Systems in the Suba District, Bogotá-Colombia,” Gestión y Ambiente, vol. 21, no. 1, p. 41, 2018.
[4] M. O. Chávez Can, Uso de imágenes de satélite de alta resolución espacial en la detección de cultivos agrícolas en el municipio de Patizcá, Chimaltenango, Ph.D. dissertation, 2021.
[5] S. Khorram, F. H. Koch, C. F. Van der Wiele, and S. A. Nelson, Remote Sensing, Springer, 2012.
[6] A. Vijayakumar and S. Vairavasundaram, “YOLO-based object detection models: A review and its applications,” Multimedia Tools and Applications, vol. 83, pp. 83535–83574, 2024.
[7] European Space Agency (ESA) & European Commission, “Copernicus Sentinel-2: A multispectral high-resolution land monitoring mission,” Copernicus Programme, 2024.
[8] J. D. Lencinas and A. Siebert, “Relevamiento de bosques con información satelital: Resolución espacial y escala,” Quebracho - Revista de Ciencias Forestales, vol. 17, . 101–105, 2009.
[9] Instituto Geográfico Agustín Codazzi (IGAC), “Observatorio de la Tierra y el Territorio,” 2024.
[10] SIATA – Sistema de Alerta Temprana de Medellín y el Valle de Aburrá, . 2025.
[11] P. S. P. Reyes et al., “Determinación de la pérdida de cobertura vegetal en el Cantón Manta (Periodo 2000–2022),” 2024.
[12] M. Reyes and I. Lizarazo, “Convolutional neural network-based semantic segmentation model for land cover classification in páramo ecosystems,” 2025.
[13] S. Razakarivony and F. Jurie, “Vehicle detection in aerial imagery: A small target detection benchmark,” Journal of Visual Communication and Image Representation, 2015.
[14] P. Ebel, A. Meraner, M. Schmitt, and X. X. Zhu, “Multisensor data fusion for cloud removal in global and all-season Sentinel-2 imagery,” IEEE Transactions on Geoscience and Remote Sensing, 2020.